

TP5 BIG DATA

Moteur de recherche semantique et analytique sur des logs massifs

Apache Spark - PostgreSQL/pgvector - Sentence-Transformers - FastAPI - Streamlit

Tati Youcef Mostefai Mounir Sofiane 2025-2026

CONTEXTE

Problematique

Les systemes distribues generent des volumes importants de logs textuels. Une recherche par mots-cles reste limitee lorsque les memes incidents sont formules differemment.

- Volume recommande par le sujet : au moins 500 000 entrees.
- Besoin : retrouver des messages similaires, pas seulement identiques.
- Objectif : combiner recherche semantique et analyse operationnelle.

Question centrale

Comment transformer des logs massifs en une base interrogeable par similarite semantique et par analyses temporelles ?

Fonctionnalites attendues

Pipeline Big Data

Ingestion, nettoyage, normalisation et partitionnement avec Apache Spark.

Recherche vectorielle

Generation d'embeddings, stockage dans pgvector et index HNSW.

Analytique

Erreurs frequentes, logs similaires, evolution temporelle et comparaison mots-cles.

Code source documente

Base vectorielle indexee

Rapport technique

Interface de demonstration

DATASET

OpenSSH - LogHub 2.0

638 947

logs bruts

38

evenements LogHub

41

messages normalises
distincts

2024


annee configurable

```
Dec 10 06:55:48 LabSZ sshd[24200]:  
Failed password for invalid user webmaster from 173.234.31.186 port 38926 ssh2
```

Le dataset contient les logs bruts, un CSV structure avec EventId et EventTemplate, ainsi qu'une table de templates et occurrences.

ARCHITECTURE

Chaine de traitement



- Spark parse les prefixes syslog et joint les fichiers LogHub.
- PostgreSQL conserve les logs nettoyes et les metadonnees.
- pgvector indexe les embeddings par distance cosinus.
- FastAPI expose un contrat applicatif reutilisable.
- Streamlit consomme uniquement l'API.
- La CLI rend le pipeline reproductible.

Nettoyage et structuration

Parsing

Extraction de la date, heure, hôte, service, PID et contenu métier.

Normalisation

Utilisation des templates LogHub pour réduire le bruit des IP, ports et utilisateurs.

Partitionnement

Sortie Parquet partitionnée par niveau : INFO, WARNING, ERROR, CRITICAL.

Le CSV traite sert au chargement rapide par COPY, tandis que le Parquet reste disponible pour des analyses batch supplémentaires.

Schema PostgreSQL + pgvector

- `log_entries` : toutes les lignes de logs nettoyes.
- `event_templates` : templates LogHub et occurrences.
- `message_embeddings` : embeddings des messages normalises distincts.
- `pipeline_runs` : traces d'execution du pipeline.

Index vectoriel

```
CREATE INDEX ... USING hnsw  
(embedding vector_cosine_ops);
```

VECTORISATION

Un vecteur par message normalise

Les embeddings ne sont pas stockes pour chaque ligne brute. Ils sont calcules pour les messages normalises distincts, puis relies aux logs par `normalized_message`.

- Reduction forte du cout de calcul.
- Conservation de toutes les occurrences originales.
- Recherche toujours possible sur les 638 947 logs.

SIMILARITE

1 - distance_cosinus

Recherche sémantique

TP5 - Logs OpenSSH

Logs638 947

Coverage100.0%

Events38

Period2024-01-01 → 202...

Recherche Comparaison Logs similaires Analytique Benchmarks

Requete sémantique

failed password for invalid user

NiveauALL

Resultats20

Rechercher

id	line_id	log_timestamp	level	event_id	similarity	raw_message
36424	291017	2024-01-01T00:15:58	ERROR	E25	0.6778	Failed password for invalid user ubnt from 188.166.228.127 port 48764 ssh2
116573	291022	2024-01-01T00:16:02	ERROR	E25	0.6778	Failed password for invalid user admin from 188.166.228.127 port 52156 ssh2
595742	291030	2024-01-01T00:16:10	ERROR	E25	0.6778	Failed password for invalid user support from 188.166.228.127 port 58616 ssh2
275640	291035	2024-01-01T00:16:13	ERROR	E25	0.6778	Failed password for invalid user user from 188.166.228.127 port 34018 ssh2
515537	291040	2024-01-01T00:16:17	ERROR	E25	0.6778	Failed password for invalid user operator from 188.166.228.127 port 36728 ssh2
355654	291051	2024-01-01T00:16:29	ERROR	E25	0.6778	Failed password for invalid user telnet from 188.166.228.127 port 46268 ssh2

Comparaison sémantique / mots-clés

Deploy

TP5 - Logs OpenSSH

Logs638 947

Coverage100.0%

Events38

Period2024-01-01 → 202...

Recherche Comparaison Logs similaires Analytique Benchmarks

Requete

brute force ssh authentication failure

Niveau

ALL

Resultats

10

Comparer

Semantique

id	line_id	log_timestamp	level	event_id	similarity	raw_message
36424	291017	2024-01-01T00:15:58	ERROR	E25	0.6681	Failed password for invalid u
116573	291022	2024-01-01T00:16:02	ERROR	E25	0.6681	Failed password for invalid u
595742	291030	2024-01-01T00:16:10	ERROR	E25	0.6681	Failed password for invalid u
275640	291035	2024-01-01T00:16:13	ERROR	E25	0.6681	Failed password for invalid u

Mots-clés

Aucun resultat.

Period

2024-01-01 → 202...


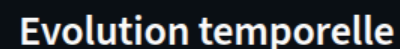
Niveau frequent

✓

failed password invalid user

☒ day ☐ hour

Analyser l'evolution



BENCHMARKS

Mesures ajoutees

100%

couverture vectorisee

HNSW

index de similarite

latence

semantique et mots-cles

coherence

score top-k proxy

COHERENCE TOP-K

$0.65 \times \text{similarite moyenne} + 0.35 \times \text{part de l'evenement dominant}$

Ce score n'est pas une precision supervisee : il complete l'analyse qualitative lorsque le dataset ne fournit pas de labels de pertinence par requete.

COMPARAISON DE MODELES

MiniLM, Multi-QA MiniLM et MPNet

tailed password invalid user

ALL

Mesurer

Model comparison

Model query

failed password invalid user

Model level

ALL

Model top-k

10

Models

all-MiniLM-L6-v2

multi-qa-MiniLM-L6...

all-mpnet-base-v2

Candidate templates

500

Comparer les modeles

model	dimension	latency_ms	coherence	avg_similarity	dominant_event	event_share	distinct_events
all-MiniLM-L6-v2	384	5878.51	0.3516	0.487	E25	0.1	10
multi-qa-MiniLM-L6-cos-v1	384	5715.64	0.3522	0.4879	E25	0.1	10

Couverture des exigences

Cas pratiques imposes

- Logs similaires a une erreur critique.
- Groupes d'erreurs frequentes.
- Evolution temporelle des erreurs similaires.
- Comparaison avec recherche par mots-cles.

Verification technique

- Pipeline complet sur 638 947 logs.
- Base pgvector indexee.
- API et interface operationnelles.
- Tests unitaires : 10 passes.

CONCLUSION

Apports du projet

- Architecture Big Data complete et reproductible.
- Recherche semantique appliquee a des logs massifs.
- Stockage vectoriel indexe avec PostgreSQL et pgvector.
- Analyse des erreurs recurrentes et de leur evolution.

Perspectives

Ajouter des labels de pertinence, evaluer plus de datasets LogHub et combiner recherche lexicale et vectorielle dans un score hybride.