

TP5 BIG DATA

Moteur de recherche sémantique et analytique sur des logs massifs

Apache Spark - PostgreSQL/pgvector - Sentence-Transformers - FastAPI - Streamlit

Tati Youcef Mostefai Mounir Sofiane 2025-2026

Retrouver le sens, pas seulement les mots

Dans un système distribué, les logs sont nombreux, répétitifs et souvent formulés avec des valeurs différentes : IP, ports, utilisateurs, PID ou timestamps.

- La recherche par mots-clés rate des messages proches mais reformulés.
- Le sujet demande une chaîne Big Data sur au moins 500 000 logs.
- Notre objectif : chercher par similarité sémantique puis analyser les erreurs.

Question centrale

Comment transformer des logs OpenSSH massifs en une base exploitable pour la recherche, la comparaison et l'analyse opérationnelle ?

638 947 logs OpenSSH traités de bout en bout

638 947

logs bruts

38

types d'événements

41

messages normalisés

384

dimensions vectorielles

Logs OpenSSH



Spark



CSV + Parquet



**PostgreSQL +
pgvector**



FastAPI



Streamlit

La CLI rend chaque étape reproductible : préparation, chargement, embeddings, indexation, statistiques et benchmarks.

PIPELINE TECHNIQUE

Prétraiter, vectoriser, indexer

Spark

Parse les préfixes syslog, nettoie les champs et joint les templates LogHub.

Embeddings

Calcule un vecteur par message normalisé distinct avec all-MiniLM-L6-v2.

pgvector

Stocke les vecteurs et accélère la recherche par un index HNSW en distance cosinus.

SCORE AFFICHÉ

similarité = 1 - distance_cosinus

Recherche, comparaison et analyse dans Streamlit

Deploy

TP5 - Logs OpenSSH

Logs

Coverage

Events

Period

638 947

100.0%

38

2024-01-01 → 202...

Recherche

Comparaison

Logs similaires

Analytique

Benchmarks

Requete semantique

wrong password

Niveau

ALL

Resultats

20

Rechercher

id	line_id	log_timestamp	level	event_id	similarity	raw_message
36424	291017	2024-01-01T00:15:58	ERROR	E25	0.5313	Failed password for invalid user ubnt from 188.166.228.127 port 48764 ssh2
116573	291022	2024-01-01T00:16:02	ERROR	E25	0.5313	Failed password for invalid user admin from 188.166.228.127 port 52156 ssh2
595742	291030	2024-01-01T00:16:10	ERROR	E25	0.5313	Failed password for invalid user support from 188.166.228.127 port 58616 ssh2
275640	291035	2024-01-01T00:16:13	ERROR	E25	0.5313	Failed password for invalid user user from 188.166.228.127 port 34018 ssh2

Exigences couvertes et mesures ajoutées

Cas pratiques du sujet

- Logs similaires à une erreur critique.
- Groupes d'erreurs fréquentes.
- Évolution temporelle des erreurs similaires.
- Comparaison avec la recherche par mots-clés.

Validation technique

- Pipeline exécuté sur 638 947 logs.
- Base pgvector indexée en HNSW.
- API et interface web opérationnelles.
- Tests unitaires : 10 passent.

Les benchmarks mesurent la latence, le volume stocké, la couverture vectorisée et une cohérence top-k basée sur la similarité et l'événement dominant.

DÉMO - 10 MINUTES

Scénario de démonstration

1. État du système

Montrer les métriques : logs, couverture, événements et période disponible.

2. Recherche

Tester une requête sémantique, comparer aux mots-clés, puis afficher les voisins d'un log.

3. Analyse

Montrer les erreurs fréquentes, leur évolution temporelle et les benchmarks.

CONCLUSION

Ce que le projet apporte

- Une chaîne Big Data complète, modulaire et reproductible.
- Une recherche sémantique adaptée aux formulations variables des logs.
- Une base vectorielle PostgreSQL/pgvector directement interrogeable.
- Une interface de démo pour explorer les résultats sans passer par le code.

Perspectives

Ajouter des labels de pertinence, tester d'autres datasets LogHub et combiner scoring lexical et vectoriel dans une recherche hybride.